

大语言模型中文议题编码能力的研究——以 DeepSeek-V4-Pro 对新闻作品标题的编码为例

摘要：内容分析法中的编码环节长期依赖人工逐条判读，存在成本高、耗时长、主观性强等问题。本研究以国产深度推理模型 DeepSeek-V4-Pro 为核心，回答其能否在严格规则约束下胜任议题编码、编码结果是否稳定可信这一问题。以 1015 条经三名编码员独立编码并通过信度检验的中国数据新闻大赛获奖作品标题为人工标注样本，分层抽样得到 314 条测试样本集。通过官方接口在受控条件下批量调用模型，以精确率、召回率、F1 值等指标量化模型编码结果与人工编码结果的吻合度，并设计六个测试用例考察基线能力、易混类目消歧、类目边界、示例与规则效果、编码稳定性与模型对照。海外模型 Claude-Opus-4.8 因标准化接口价格昂贵，仅作小样本定性参照。

测试发现，模型整体准确率为 0.662，Cohen's Kappa 为 0.608，按 Landis 和 Koch 标准属中度一致水平，以 0.002 之差未达可接受线，准确率亦未达通过线。模型误差高度系统化，集中于经济与社会民生这一对语义边界，致经济类召回率低至 0.413。提示词消融显示，追加示例或植入编码手册规则均未显著提升准确率，三种条件准确率落在 0.66 至 0.69 之间，写入规则反而加剧经济向民生的系统性漂移。同条件重复编码三次的完全一致比例仅为 0.767。作为定性参照的 Claude-Opus-4.8 模型在相同边界上呈现同方向的分歧。研究认为，大语言模型可作为议题编码的初编助手，但其系统性偏差会向上扭曲内容分析的议题分布结论，当前宜采用人机协同的初编加复核模式，而非使模型替代所有编码工作。

关键词：大语言模型；内容分析法；DeepSeek；编码信度；人机协同

0 引言

编码是内容分析法的基础工序。研究者依据预先制定的编码手册，将文本逐条归入互斥且穷尽的类目体系，进而对议题分布、媒介框架与传播趋势展开量化分析。编码质量直接决定后续全部统计结论的可信度。然而传统人工编码长期面临三重困境。其一是规模困境，大体量样本需多名编码员耗时数周乃至数月。其二是主观困境，编码员的知识背景与判断习惯差异会引入系统性偏差。其三是一致性困境，编码员之间乃至同一编码员前后的判定难以完全统一，信度系数偏低时整项研究的效度都会受到质疑。

2025 年以来，以 DeepSeek、Claude 为代表的国内外大语言模型在自然语言深度推理上取得突破，为缓解上述困境提供了新的技术可能。本研究以经过信度检验的人工编码样本为锚点，对 DeepSeek-V4-Pro 的中文议题编码能力进行评估，并辅以海外模型进行参照，借此初步观察国产与海外模型在同类任务上的表现异同。选择 DeepSeek-V4-Pro 作为核心评测对象，是因为它可经官方接口标准化调用、支持深度思考模式，能够在受控的前提下完整跑通批量流程。Claude-Opus-4.8 等海外大语言模型标准化接口调用充值起步价过于昂贵（\$100，折合人民币 680 元）。但若直接使用网页、桌面端的大模型与裸接口调用的 DeepSeek 比较各项指标，又会因为无法有效控制变量而导致模型差异与产品差异相互混淆，因此本研究仅将 Claude-Opus-4.8 模型限定为定性参照。

1 测评设计

1.1 样本与人工标注基准

本研究样本为 1015 条中国数据新闻大赛获奖作品标题。作为评判模型的人工标注基准是由三名受训编码员依据同一份编码手册独立编码、经跨编码员信度检验并对分歧协商裁定后形成的共识结果。

议题类目体系包含九类，分别为政治与军事、法律与公共安全、经济、社会与民生、健康、性别与人口、文化旅游与体育、生态环境、科技。编码手册由九条消歧规则构成，用于处理类目交叠时的取舍。

编码项	一级编码	二级编码
作品议题	T	1. 政治与军事 2. 法律与公共安全 3. 经济 4. 社会与民生 5. 健康 6. 性别与人口 7. 文化、旅游与体育 8. 生态环境 9. 科技
作品所获奖项	A	1. 一等奖 2. 二等奖 3. 三等奖 4. 优秀奖
作品所属届次	E	1. 第一届 2. 第二届 3. 第三届 4. 第四届 5. 第五届 6. 第六届 7. 第七届 8. 第八届 9. 第九届 10. 第十届
参赛主体	C	1. 985 高校 2. 211 高校 3. 非 985、211 高校 4. 港澳台及海外高校 5. 业界 6. 多所院校合作 7. 专科学校
主体所属省/自治区/直辖市/ 国家（非中国）	P	1. 安徽 2. 澳门 3. 北京 4. 福建 5. 甘肃 6. 广东 7. 广西 8. 贵州 9. 海南 10. 河北 11. 河南 12. 黑龙江 13. 湖北 14. 湖南 15. 吉林 16. 江苏 17. 江西 18. 辽宁 19. 内蒙古 20. 宁夏 21. 青海 22. 山东 23. 山西 24. 陕西 25. 上海 26. 四川 27. 天津 28. 西藏 29. 香港 30. 新疆 31. 云南 32. 浙江 33. 重庆 34. 韩国 35. 英国
主体所属区域	R	1. 华北 2. 华东 3. 华中 4. 华南 5. 东北 6. 西北 7. 西南 8. 港澳台及海外地区

图 1 编码表

1.2 抽样与测试样本集

九类议题在总体中的分布高度不均，经济、文化旅游与体育、社会与民生为高频类，政治与军事、科技、生态环境为低频类。直接随机抽样会使长尾类目样本不足、指标失真。为此本研究采用分层抽样，按各类目占总体的比例分配样本量，并对小类目设每类不少于 18 条的配额，最终得到测试样本集 314 条（见表 1）。

表 1 测试样本集分层抽样分布（共 314 条）

议题	政治军事	法律公安	经济	社会民生	健康	性别人口	文化体育	生态环境	科技
条数	18	18	63	57	37	21	62	20	18

1.3 测试用例设计

表 2 六个测试用例与通过标准

用例	名称	做法	设计意图	通过标准
1	编码基准	对 314 条全量编码，计算整体指标与各类目 F1	建立编码能力基准线	准确率不低于 0.80 且 Kappa 不低于 0.61
2	经济与民生辨别	取议题 3、4 的标	测对编码难度最大	两类 F1 不显著低

用例	名称	做法	设计意图	通过标准
		题考察归类走向	的两个议题分类的执行	于整体均值
3	政治边界判定	取可引申政治但未直指的标题	测类目边界把握，是否过度归入政治	政治类精确率不低于 0.70
4	示例与规则检验	同批标题在零样本、少样本与基线条件下各编码一遍	检验示例与规则对准确率的影响	少样本较零样本显著提升
5	稳定性检验	取 30 条同条件重复编码三次看一致率	检验编码可重复性	三次完全一致比例不低于 0.85
6	不同模型对照	模型定量编码，Claude-Opus-4.8 模型同批样本定性观察	初步看国产与海外模型异同	

1.4 提示词设计

提示词遵循角色定义、议题类目、编码手册、格式规范、约束条件五要素结构。为考察提示信息量对编码质量的影响（用例 4），本研究设计三种提示词条件。零样本条件不含有关议题分类的任何提示；少样本条件为每类补充两条典型示例；基线条件写入编码手册规则。少样本与零样本控制“示例”变量，基线与零样本控制“规则”变量。

编码基准提示词全文如下：

你是一名严谨的新闻传播学领域的内容分析编码员，需要对“中国数据新闻大赛”获奖作品的标题进行议题归类。

议题类目（9 选 1，只能选一个最核心的）：1=政治与军事；2=法律与公共安全；3=经济；4=社会与民生；5=健康；6=性别与人口；7=文化、旅游与体育；8=生态环境；9=科技。

编码手册（判定规则，务必逐条遵守）：(1) 如果影响甚广、辐射面甚大，才选 3 经济或 4 社会与民生；如果聚焦在某个具体领域，优先选那个领域。(2) 经济与民生的区别：通过生产力发展就能解决的问题，选 3 经济；当前生产力条件下，因为制度政策缺陷导致的困境，选 4 社会与民生。(3) 特别包罗万象的、含政治概念的、涉及外国或反动势力的，选 1 政治与军事。(4) 涉及特定性别、民族、职业困境的，直接选对应类目。(5) 涉及新形势下实现新发展方法、新发展观念的，选 3 经济。(6) 如果只是可以“引申”出政治问题、而非直接指向政治的，不要选 1 政治。(7) 标题含两句话或两个事实时，选更核心、更本质的那个原因所属的类目。(8) 看不明白的标题，先在心里厘清它讲的概念和问题是什么，再判定。(9) 不止一个领域受影响时，选导致这些问题的“总的原

因”所属类目。

输出格式：第一行“议题编号：<1-9 中的一个数字>”；第二行“议题名称：<对应名称>”；第三行“判定理由：<一句话说明归类依据>”。

约束条件：必须且只能输出一个议题编号，不得输出 0、不得多选、不得为空；即使标题信息很少或为英文，也要基于语义做出最合理的单一归类；严格按三行格式输出，不输出任何额外内容。

少样本条件为每类补充两条人工构造的典型示例，如“长江流域水质十年治理成效”归 8 生态环境，示例不取自测试样本集，以避免示例与受测样本重合而虚高成绩。两种条件的角色定义、格式规范与约束条件均与基线完全相同。

1.5 测评执行

测评通过程序自动完成调用、解析与核对，核心流程伪代码呈现如下：

算法 1 单条标题的编码调用与解析

输入：标题 `title`，系统提示词 `prompt`

输出：议题编号 `code` 或未解析标记

步骤 1 构造请求：指定模型为 DeepSeek-V4-Pro，消息为 [系统: `prompt`; 用户: “请对以下标题进行议题编码：标题: ” + `title`]，

开启深度思考模式，推理强度设为 Max，输出额度初设 4000

步骤 2 发送请求，取回正式应答 `content` 与思维链 `reasoning`

步骤 3 按三级顺序从 `content` 解析编号：

- 匹配“议题编号：N”且 N 在 1 至 9 之间，则返回 N
- 否则按“议题名称”行映射到对应编号
- 否则取全文首个孤立出现的 1 至 9 数字

步骤 4 若 `content` 为空或解析失败：

先从思维链末尾尝试解析；仍失败则将输出额度乘 1.8（上限 12000）后重试

步骤 5 遇网络或接口错误时按指数退避等待后重试，最多 4 次；全部失败记为未解析

算法 2 样本集的批量编码与结果记录

输入：测试样本集，系统提示词 `prompt`

步骤 1 读取样本表；载入既有结果文件，跳过已成功编码的样本

步骤 2 以 6 至 8 个并发线程对其余样本逐条执行算法 1

步骤 3 每完成一条，立即将序号、标题、人工编码、模型编号、应答全文、思维链追加写入结果文件

步骤 4 全部完成后回写逐条对照表，计算准确率、Kappa、各类目精确率、召回率、F1 与混淆矩阵

测试中，314 条样本全部成功取得编号，其中 1 条语义复杂标题因思维链耗尽输出额度而返回空应答，重新解析成功后取得编号。

2 测评结果

2.1 整体编码能力（用例 1）

DeepSeek-V4-Pro 对 314 条标题全部成功编码。整体指标见表 3。模型整体准确率为 0.662，低于 0.80 的通过线。Cohen's Kappa 为 0.608，按 Landis 和 Koch 标准属中度一致水平，距 0.61 的可接受线仅差 0.002。据此判定，模型编码处于中度一致、逼近可接受但准确率不够格的水平，用例 1 未达通过标准。

表 3 用例 1 整体指标

指标	数值	判读
整体准确率	0.662	低于 0.80 通过线
Cohen's Kappa	0.608	中度一致，以 0.002 之差未达可接受线
宏平均 F1	0.665	类目间表现不均衡

模型表现高度不均衡，各类目精确率、召回率与 F1 见图 2。政治与军事、健康、文化旅游与体育、生态环境四类较为稳健，F1 在 0.73 至 0.80 之间。经济、科技、社会与民生、法律与公共安全四类明显偏弱，F1 在 0.52 至 0.62 之间。其中经济类召回率仅为 0.413，为九类最低，意味着近六成经济类标题被判去了其他类目，这是拉低整体准确率的主要原因。




图 2 各类目精确率、召回率与 F1

2.2 误差结构

误差是否随机，决定了模型可否经简单校正后使用。卡方检验显示误判分布显著偏离随机，卡方值为 130.6，自由度为 37， p 小于 0.001，说明错误高度集中于特定类目对而非均匀散布。完整的误判流向见图 3 的混淆矩阵，排名前列的误判类目对见图 4。




图 3 议题编码混淆矩阵




图 4 主要误判类目对，箭头由人工编码指向模型预测

误差呈现清晰的结构。最突出的一类是经济被判为社会与民生，共 20 条，几乎以一己之力压低了经济类的召回。其后是科技被判为法律与公共安全、社会与民生被判为经济、文化旅游与体育被判为经济，各 5 条，社会与民生、性别与人口之间亦有少量互混，这些误判都集中在语义相邻的类目之间。

2.3 经济与民生的边界混淆（用例 2）

专取人工编码为经济与社会民生的标题构成子集，其内部准确率仅为 0.558，经济与民生两类的 F1 均明显低于整体宏平均，用例 2 未达通过标准。透过模型自述的判定理由可以看清其归类逻辑，即模型倾向于把弱势群体的生存困境一律读作民生。例如对脱贫攻坚题材，模型判为社会与民生，理由是精准脱贫直接聚焦贫困人口生活改善、属社会民生领域核心议题，而人工编码认为上述困境究其核心属于经济发展议题，归根到底是需要通过生产力的发展得以解决的。这是一种有内在逻辑的系统性分歧，不过，在实际的编码过程中，哪怕是经过训练与多轮预编码的人类编码员面对经济与民生议题也出现了分辨不清的状况。

2.4 政治类目的边界把握（用例 3）

政治与军事类的精确率为 0.727，高于 0.70 的通过线，被误归入政治

的仅 6 条，用例 3 通过。模型没有逢国家叙事就归入政治的过度倾向。进一步审视这 6 条误判，多数属于编码手册的局限。甲午轮回、忆抗美援朝志愿军等标题被判为政治与军事，模型抓住了其中的战争内核，而人工编码则认为其为历史文化相关作品。“沉默的出版”被模型读作审查与意识形态议题，而人工编码视其为出版行业的经济困境；“行行有军影”聚焦退役军人的职业跨界，模型抓住军人身份归入军事，人工编码则视其为就业经济议题。由于上述议题类目之间的分类规则没有在编码手册中阐明，导致模型使用更贴近字面的政治军事含义进行判断。同时这也提示我们，使用大语言模型编码并将其结果与人工编码进行对照，还有优化编码手册的作用，从下文的测试与分析中依旧可见。

2.5 提示词条件的影响（用例 4）

三种提示词条件下，同一批 314 条标题的整体准确率见图 5。零样本为 0.688，少样本为 0.694，基线为 0.662。配对显著性检验表明，零样本与少样本之间差异不显著， p 为 0.839。零样本与基线之间差异亦不显著， p 为 0.291。少样本未带来显著提升，用例 4 未达通过标准。




图 5 三种提示词条件下的整体准确率

这一结果是反直觉的。三种条件的准确率落在 0.66 至 0.69 的窄带内，彼此没有统计学差异，说明模型的准确率瓶颈不在指令是否充分，追加示例或补充规则都影响甚微。更值得注意的是，写入九条编码手册后准确率不升反降，且经济类的漂移随提示信息量增加而加剧，经济类召回率由零样本的 0.508 降至少样本的 0.460，再降至基线的 0.413，经济被判为民生的标题相应由 13 条增至 16 条再增至 20 条。从该条件下模型自述的判定理由可以发现，它频繁援引规则中“制度政策缺陷导致的困境归民生”的半句，却几乎从不援引“通过生产力发展就能解决的问题归经济”的另半句。人类编码员凭借某种稳定的隐性惯例高度一致地完成了归类，而规则要求模型先完成“该问题靠生产力发展还是制度完善来解决”的反事实判断再行归类，这一判断在仅有一行标题的条件下难以稳定完成，模型于是退而抓住规则中与“以人为本”直觉一致的半句并放大执行。隐性条件或许本身难以经由成文规则交给模型执行。

2.6 编码的可重复性（用例 5）

取 30 条样本，在完全相同的条件下连续编码三次。三次完全一致的比例为 0.767，两两平均一致率为 0.811，用例 5 未达 0.85 的通过线。这意味着即便在最高思考强度下，模型推理过程自身仍带来约四分之一样本至少一次的波动。7 条不一致样本无一例外都是语义边界模糊、含多个事实或高度隐喻的标题（见表 4），可见“准不准”与“稳不稳”在同一批难题上同时失守。

表 4 三次编码不一致的样本

序号	人工编码	三次结果	标题节选	不稳定原因
379	生态	健康、生态、民生	热浪扑向谁	隐喻
736	文化体育	文化、文化、健康	速滑首枚的生命通道	隐喻、多义
829	民生	民生、科技、民生	外卖要上天，首先得落地	隐喻、多义

序号	人工编码	三次结果	标题节选	不稳定原因
856	科技	民生、法律、科技	生命智驾，小米事故舆论	科技与治安混淆
938	经济	民生、民生、政治	360 行，行行有“军”影	就业与军事混淆
939	科技	科技、科技、民生	“智慧”红绿，让等待不再漫长	科技与民生混淆
998	生态	科技、经济、生态	种源方舟，世纪保卫战	隐喻

2.7 与 Claude-Opus-4.8 模型的定性对照（用例 6）

作为定性对照，研究抽取 45 个样本，依同一份提示词在 Claude-Opus-4.8 模型的桌面端产品环境内提交编码。Claude-Opus-4.8 模型与人工编码一致 36 条，一致率为 0.80。9 条分歧中有 7 条恰落在经济与民生之分，Claude-Opus-4.8 模型同样将护工、乡村医生、考公一代、医生群体、乡村教师、养老护理员等读作民生而非经济。另有两条分歧涉及隐喻或疑难标题。代表性分歧见表 5。

表 5 Claude-Opus-4.8 模型与人工编码不一致的代表样本

标题节选	人工编码	Claude-Opus-4.8 模型
护工的生存图鉴	经济	社会与民生
数说中国乡村医生	经济	社会与民生
考公一代	经济	社会与民生
养老护理员现状	经济	社会与民生
乡村教师的隐形付出	经济	社会与民生

值得强调的是，部分分歧也反映出了人工编码在个别样本上的可商榷之处。DeepSeek-V4-Pro 与 Claude-Opus-4.8 模型来自不同厂商、不同技术路线，却在经济与民生边界上呈现同一方向的分歧。这表明问题不全在某一个模型，而部分源于该类目对在标题语义上本就高度交叠，也源于成文编码手册对这条边界的界定不够操作化，需要进一步优化。

2.8 用例的执行结果

为便于总览，将六个用例的关键指标、结果与通过情况汇总于表 6。六个用例中，仅政治边界判定一项通过，其余均未达预设通过标准。

表 6 用例的执行结果与通过判定

用例	关键指标	结果	通过情况
1 编码基准	准确率; Kappa; 宏平均 F1	0.662; 0.608; 0.665	未通过
2 经济与民生辨别	两类 F1 与子集准确率	经济 0.520, 民生 0.599, 子集准确率 0.558	未通过
3 政治边界判定	准确率	0.727, 误归入政治仅 6 条	通过
4 示例与规则检验	三种条件准确率	零样本 0.688, 少样本 0.694, 基线 0.662, 差异均不显著 (p=0.839, p=0.291)	未通过
5 稳定性检验	三次完全一致比例; 两两平均一致率	0.767; 0.811	未通过
6 不同模型对照	与人工编码的一致条数	Claude-Opus-4.8 模型 36/45 条一致, 边界分歧与 DeepSeek 同向	

3 分析与讨论

以下从技术、产品、传播、伦理四个层面展开讨论。

3.1 技术层面

模型对语义指向单一、领域显性的标题，如政治与军事、健康、文化旅游与体育、生态环境，模型判断得快而准，F1 在 0.73 至 0.80 之间，且格式遵循极佳。这说明模型完全具备读懂中文标题主旨并执行结构化输出的基础能力。其薄弱之处集中在语义边界模糊、需要多步规则推理的类目对上，主要表现为经济与民生互混。原因可归结为三点。其一是标题信息稀薄，仅有一行标题而无正文，可供消歧的语义线索有限。其二是隐性规则需要多步推理，例如判断一个问题靠生产力发展还是制度完善来解决再决定归类，推理链条一旦过长结果就易失守，模型对显性领域规则的遵循

明显强于对隐性规则的遵循。其三是编码类目本身交叠，编码手册操作性不强，连受训的人类编码员在形成共识之前也需协商（区别在于人类编码员协商后能输出一致且稳定的结果。模型目前无法做到）。结合 Claude-Opus-4.8 模型在同一边界上的同方向分歧，更应反思将经济与社会民生设为两个互斥类目，在编码上是否过于理想化。

3.2 产品层面

本研究经标准化接口而非对话界面使用模型。对研究用途而言，接口就是模型的产品形态，参数如何封装、输出以何种机制交付、格式能否被程序稳定解析、能否被标准化批量调用，共同构成研究者与模型之间真实的交互设计，并实际影响了本次测评的过程与表现。

参数的封装方式甚至反过来塑造了测试方案本身。深度思考模式下温度等随机性参数不生效，研究者无法人为注入扰动来考察输出波动，稳定性检验因此只能定义为同条件重复调用的一致率。这表明产品层面的设计选择不仅影响使用体验，还直接划定了研究者能够设计哪些测试。

具体到本次测评，深度思考模式带来更稳的推理，但也带来先输出思维链再给出答案的特性，少数复杂标题会在输出额度内只顾思考而来不及作答，返回空内容。这是该模式用于批量结构化输出时的真实工程隐患，需要在调用侧预留充足额度并对空响应自动重试。从提示工程的边际收益看，本研究的消融结果表明，相对仅给类目定义，追加示例或补充规则均未带来显著提升，提示优化在本任务上已接近收益上限，真正的瓶颈在类目体系本身。从可获取性看，DeepSeek 可经官方接口标准化、可复现地批量调用，这是它能完整跑通本测评的前提，而 Claude-Opus-4.8 模型仅能经产品环境访问、且标准化接口价格高昂，无法在受控条件下批量编码。能否被标准化、低成本地调用，直接决定了一个模型能否进入严肃的量化研究流程，这是常被忽略却极为现实的可操作性维度，也正是二者在

本研究中分别承担定量核心与定性参照角色的根本原因。

3.3 传播层面

模型 0.413 的经济召回率意味着，若研究者直接采用模型全自动编码而不复核，大量经济议题会被系统性地误计入社会与民生。这种误差不是随机的，在大样本下不会相互抵消。其后果是内容分析得出的议题分布会低估经济、高估社会民生。若这份议题分布进一步用于舆情研判、媒介框架分析或传播决策，偏差会沿着链条层层放大。换言之，人工智能编码的危险不在于它会出错，而在于它以一致的方式出同一种错。系统偏差比随机误差更隐蔽，因为它能让一份内部高度自洽的报告整体偏离真实。

3.4 伦理层面

当模型编码出错导致内容分析结论失实，进而影响据此发表的论文或决策时，责任如何归属。本研究认为首要责任在研究者。模型只是工具，选择是否采用模型编码、是否复核，是研究者的学术判断，不能以模型如此判定为由推卸责任。模型提供方应对其能力边界与已知偏差负有如实披露义务，但不能替研究者承担方法选择之责。由此引出两条底线。其一是披露义务，凡使用模型参与编码，须在方法部分说明所用模型、版本、提示词、调用参数与人工复核比例，使结论可被审视、可被复现。其二是复核义务，在模型尚未达到几乎完全一致的水平之前，模型编码结果不应不经人工复核而直接采信。本研究 Kappa 为 0.608，仅属中度一致、尚未站上可接受线，距几乎完全一致更远，恰说明此刻全自动替代人工在学术上尚不可接受。

4 改进建议

本研究的评测对象是 DeepSeek-V4-Pro 这一工具，以下三条建议针对模型及其接口产品本身。

一、增强语义相邻类目的细粒度判别能力。测评显示，模型在经济与

社会民生、科技与法律公共安全等相邻类目上系统性混淆，根源是对职业群体生计与产业发展、人口结构与民生服务等社会科学细颗粒语义边界的把握不足。建议在面向中文社会科学文本的对齐与评测中纳入这类易混类目对，提升模型在给定互斥类目体系、被要求强制单选时的边界判别力，而不仅追求通用语义理解。

二、改进深度思考模式的输出稳定性与额度分配。同条件重复编码三次的完全一致比例仅为 0.767，且复杂标题会因思维链耗尽输出额度而返回空应答。建议工具在深度思考模式下提供可复现的确定性选项，例如可设随机种子或稳定档位，并在机制上保证正式答案的输出额度不被思维链挤占，从根本上消除空应答这一隐性失败，使输出对研究用途足够可靠。

三、在结构化输出中原生提供置信度。模型目前只给出单一编号与一句理由，不提供把握程度，研究者无从知道哪些判定可信、哪些需要复核。建议工具在结构化输出中原生附带每条判定的置信度，或在低置信时给出次优候选类目，使研究者可据置信度自动分诊出需人工复核的样本，把黑箱式单选变为可分诊的辅助工具。

5 结语

本研究将大语言模型从提效工具翻转为被检验的能力主体，以经三名编码员信度检验的人工编码为锚点，对 DeepSeek-V4-Pro 的中文标题议题编码能力进行了系统而可复现的测评。研究表明，模型仅达到中度一致、逼近可接受线但准确率不够格的水平，能稳健处理语义显性的标题，却在语义交叠的类目边界上犯下一致而系统的错误，且这种系统偏差与海外模型 Claude-Opus-4.8 模型同方向。追加示例或写入规则均未显著改善，重复编码的完全一致率亦仅为 0.767。对智能媒体与传播研究而言，这一发现的意义不止于模型还不够好，更在于揭示了一条方法论红线，即当人工智能以高度自洽的方式系统性地偏离真实时，最大的风险不是它出错，而

是研究者不再复核。因此本研究主张，当前阶段应由深度推理负责初编、由人类负责校验纠偏，构建初编加复核的人机协同模式，而非以模型全自动替代人工编码，从而在释放效率红利的同时守住编码信度这一量化研究的生命线。

参考文献

- [1] DeepSeek-AI. DeepSeek-V4 Technical Report[R/OL]. (2026-04-24).
- [2] 于晖, 宋金戈, 王乐. 大语言模型辅助的功能语篇分析: 理论、方法与实践[J]. 外语电化教学, 2024(5): 43-51, 111.
- [3] 李浩楠, 周泽奇, 梁晓波. 基于深度推理模型的自动化语料标注: 以隐喻标注为例[J/OL]. 情报杂志, 2025.